

# NAS 파일 검색 품질 개선 보고서

작성일: 2026-06-01 | 대상: NAS 자료 검색 모듈 (nas\_search) | 작성: AI 자동화  
하이브리드 검색 도입 — 의미검색(벡터) + 정확매칭(전문검색) 결합

## 1. 한 줄 요약

NAS 약 1.2만 개 파일은 이미 임베딩되어 벡터DB(pgvector)로 의미검색이 동작 중이다. 이번 작업은 벡터검색이 약한 '정확한 코드·숫자·고유명사' 매칭을 전문검색으로 보완하여 검색 정확도를 끌어올린다. 추가 AI 토큰 비용 0원, 재임베딩 불필요.

## 2. 현재 구조 (이미 갖춘 것)

- 임베딩 모델: multilingual-e5-large (1024차원), 로컬 연산 → 호출 비용 없음
- 벡터 저장: PostgreSQL + pgvector, cosine 유사도 검색
- 체크 3종: 본문 / 파일명·경로 / Claude 키워드요약 — 검색 적중률 보강 설계 적용됨
- 필터: 파일종류(pdf·word·ppt·hwp·excel)·폴더경로·수정일 범위

즉, '벡터DB로 자연어 의미검색'은 이미 온전히 동작한다. 부족한 것은 임베딩의 양이 아니라, 정확 토큰 매칭이다.

## 3. 문제 — 순수 벡터검색의 한계

임베딩은 단어를 '의미 좌표'로 압축하기 때문에 비슷한 숫자·코드를 구분하지 못한다. 의미·취향스 검색에는 강하지만 다음에 약하다:

- 품번 / 관리번호 (예: 12865-24-008320X)
- 금액 / 수치 (예: 9,834USD)
- 모델명 · 회사명 · 날짜 등 고유 토큰

실제로 면장 등에서 정확한 품번·금액 검색이 빗나가는 원인이 여기에 있다.

## 4. 개선 방향 — 하이브리드 검색

벡터검색을 버리는 것이 아니라, 정확검색(전문검색)을 나란히 두고 두 결과를 RRF(순위 결합)로 합친다. 의미와 정확도를 동시에 잡는 업계 표준 방식이다.

사용자 질문: "GUCCI 가방 면장 2024"

|  
| — [A] 의미검색 : 쿼리 임베딩(로컬) → pgvector cosine → 상위 N  
| — [B] 정확검색 : Postgres 전문검색(tsvector/trigram) → 상위 N  
| — 품번·금액·모델명·날짜 담당



[RRF 결합] 두 순위를 점수로 합산 → 최종 상위 k 반환

A·B·결합 전 과정이 로컬 임베딩과 Postgres 내부에서 끝나므로 AI 호출 비용이 발생하지 않는다.

## 5. 이번 작업 범위

- 1단계: 전문검색 컬럼·인덱스 추가 (DB 마이그레이션, tsvector + trigram)
- 2단계: 기존 1.2만 체크의 본문을 전문검색 컬럼으로 1회 채움(backfill)
- 3단계: 검색 API에 전문검색 + RRF 결합 로직 추가
- 4단계: 실제 질의 셋으로 개선 전·후 정확도 비교

보류: Open WebUI 연동 'AI 답변 생성(RAG)'은 Open WebUI 사용 여부가 미정이므로 이번 범위에서 제외. 검색 품질 우선.

## 6. 비용 · 리스크

- AI 토큰 비용: 0원 (로컬 임베딩 + DB 내부 처리)
- 재임베딩: 불필요 — 기존 임베딩 자산 그대로 재사용
- 리스크: 낮음 — 컬럼·인덱스 추가 방식이라 기존 의미검색 동작을 보존
- 선택 확장(다음): Reranker 재정렬. 로컬 모델은 0원, LLM 방식은 검색 1회당 약 8~9원(추정)

## 7. 기대 효과

- 품번·금액·모델명 등 정확 토큰 검색 정확도 대폭 개선
- 기존 의미검색 품질은 그대로 유지
- 향후 Reranker · RAG 답변으로 단계적 확장 가능한 토대 확보

※ 비용 수치는 추정치이며 실제 과금은 텐센트/Anthropic 콘솔 기준. 본 문서는 작업 착수 보고용 요약본.